Reverzní inženýrství

4. Disassembling a obfuskace

Ing. Tomáš Zahradnický, EUR ING, Ph.D. Ing. Martin Jirkal



České vysoké učení technické v Praze Fakulta informačních technologií Katedra počítačových systémů

Verze 18. listopadu 2017



Obsah I

- Disassembling
 - Lineární průchod
 - Rekurzivní průchod
 - Rozšířený lineární průchod
 - Hybridní přístup
- Obfuskační techniky
 - Motivace
 - Obfuskace rozložení
 - Transformace řízení
- Obfuskační techniky Transformace řízení
 - Neprůhledné predikáty a proměnné
- Obfuskační techniky Transformace výpočtu
 - Vkládání mrtvého nebo nerelevantního kódu
 - Rozšíření podmínek cyklů
 - Konverze reducibilního CFG na nereducibilní

Obsah II

- Odstranění knihovních volání a programovacích idiomů
- Tabulková interpretace
- Přidání redundantních argumentů
- Paralelizace kódu

- Obfuskační techniky Transformace agregace
 - Inlining
 - Outlining
 - Interleaving
 - Klonování
 - Transformace smyček

Disassembling

Disassembling

Disassembling je proces překladu binárního kódu do kódu v člověkem čitelném assembleru cílového CPU.

- Aplikace, která disassembling provádí, se nazývá disassembler.
- Disassembly (výsledek disassemblingu) se používá k provádění statické analýzy kódu a v rámci debuggeru i pro dynamickou (živou) analýzu.
- Disassembly:
 - obsahuje obrovské množství řádek kódu;
 - postrádá množství informace, která existovala v čase kompilace (názvy proměnných, ladící informace, názvy návěští), kvůli jejich odstranění během kompilace;
 - míchá kód a data jak je můžeme rozlišit?
- K disassemblingu jsou dva základní přístupy lineární průchod (linear sweep) a rekurzivní průchod (recursive traversal) [4]. Každý má své kladv a zápory.

Lineární průchod

Lineární průchod

Lineární průchod disassembluje lineárně, bajt po bajtu, od začátku sekce .text až do jejího konce.

- Rychlý a jednoduchý.
- PowerPC má instrukce s pevnou délkou 4 B.
- x86 používá instrukce s proměnlivou délkou, 1–15 B. Teoreticky je možné vytvořit nekonečně dlouhé instrukce pomocí redundantních prefixů, ale cokoliv delšího než 15 B vyvolá výjimku.
 - cc int3.
 - cd 03 int 3.
 - f0 65 81 84 d8 78 56 34 12 ef cd ab 90 lock add dword ptr gs:[eax+ebx*8+12345678h], 90abcdefh.
- Jakmile je jedna instrukce disassemblována, pokračuje se další instrukcí. Tento proces je opakován přes celou sekci .text.



5 / 62

Nejednoznačný tok kódu

WinDbg 6.12.0002.633

Původní kód

```
xor eax, eax
----jz good // VZdy skočit
_emit Oxf0
_emit Ox81
_emit Ox84
v _emit Ox98
good: mov eax, ebx
mov eax, ebx
mov eax, ebx
mov eax, ebx
```

IDA Pro 6.7

```
00402cd8 xor eax, eax
00402cda jz short near ptr loc_402CDC+5
00402cdc db 3Eh
00402cdc lock add dword ptr [eax+ebx*4-3C743C75h], 0C38BC38Bh
```

OllyDbg 2.01

```
00402cd8 33c0
              xor eax, eax
00402cda 7405
              je short 00402ce1
              db f0
                         // Správně!
00402cdc f0
00402cdd 3e db 3e // Správně!
00402cde 81 db 81
                       // Správně!
00402cdf 84 db 84
                        // Správně!
00402ce0 98
                         // Spatně!
            cwde
00402ce1 8bc3 mov eax, ebx // Správně!
00402ce3 8bc3 mov eax,ebx // Správně!
              mov eax, ebx // Správně!
00402ce5 8bc3
00402ce7 8bc3
              mov eax, ebx // Správně!
```

Promíchaný kód & data

```
0.000> 11 011d4780 I.200
 011d4780 55
                            push ebp
 011d4838 83bdd0feffff03
                            cmp dword ptr [ebp-130h],3
 011d483f 7727
                            ia
                                 011d4868
 011d4841 8b8dd0feffff
                            mov ecx, dword ptr [ebp-130h]
                            imp_dword_ptr_ds:[011d490c+ecx*4]
 011d4847 ff248d0c491d01
                            call func0 (011d11ae)
 011d484e e85bc9ffff
 011d4853 eb13
                            jmp 011d4868
 011d4855 e82cc9ffff
                            call func1 (011d1186)
                            imp 011d4868
 011d485a eb0c
 011d485c e820c9ffff
                            call func2 (011d1181)
                            jmp 011d4868
 011d4861 eb05
 011d4863 e8fbc8ffff
                            call func3 (011d1163)
 011d4868 33c0
                                eax,eax
 011d4897 5d
                            pop
                                ebp
 011d4898 c21000
                            ret
                                 10h
 011d489b 90
                            nop
 011d489c 05000000a4
                            add eax.0A4000000h
 011d48a1 48
                            dec eax
 011d48a2 1d01f4ffff
                            sbb
                                eax, OFFFFF401h
 011d490c 4e
                            dec
                                 esi
                                                                 // Data v sekci .text!
 011d490d 48
                                                                // Data v sekci .text!
                            dec eax
 011d490e 1d0155481d
                            sbb eax, 1D485501h
                                                                // Data v sekci .text!
 011d4913 015c481d
                            add
                                 dword ptr [eax+ecx*2+1Dh],ebx
                                                               // Data v sekci .text!
                                 dword ptr [ebx+48h].esp
 01144917 016348
                                                                // Data v sekci .text!
 011d491a 1d01cccccc
                            sbb eax,0CCCCCC01h
                                                                // Data v sekci .text!
```

Lineární průchod - pokračování

- Jak jsme viděli, lineární průchod slepě disassembloval jednu instrukci po druhé. To bylo funkční, pokud jsme s disassemblováním začali na začátku funkce (push ebp na 011d4780). Výsledky byly zpočátku OK, později se ale disassembler nechal zmást:
 - nejednoznačným tokem kódu;
 - daty uvnitř kódu.
- Oba případy vedly na nesmyslnou disassembly!
 - → Disassembler používající poze linární průchod (WinDbg, gdb, objdump
 [3]) nedokáže odlišit kód od dat.
- ightarrow Lineární průchod je sám o sobě nedostatečný ightarrow potřebujeme robustnější metodu.

Rekurzivní průchod I

Rekurzivní průchod, na rozdíl od lineárního, disassembluje kód na základě sledování jeho toku. Průchod začíná typicky na vstupním bodu programu, kde se disassembluje jeho první instrukce. Po zpracování každé instrukce je adresa nesoucí tuto instrukci označena jako navštívená. Pokud navíc šlo o instrukci způsobující skok, zapamatuje se návratová adresa (pokud existuje) a analýza rekurzivně začíná na cílové adrese skoku. Poté, co byla analýza této větve dokončena, pokračuje analýza zapamatovanou návratovou adresou.

Tento přístup:

- je pomalý;
- rozlišuje kód a data:
 - všechny nenavštívené adresy jsou považovány za data

Rekurzivní průchod II

Rekurzivní průchod, na rozdíl od lineárního, disassembluje kód na základě sledování jeho toku. Průchod začíná typicky na vstupním bodu programu, kde se disassembluje jeho první instrukce. Po zpracování každé instrukce je adresa nesoucí tuto instrukci označena jako navštívená. Pokud navíc šlo o instrukci způsobující skok, zapamatuje se návratová adresa (pokud existuje) a analýza rekurzivně začíná na cílové adrese skoku. Poté, co byla analýza této větve dokončena, pokračuje analýza zapamatovanou návratovou adresou.

Tento přístup:

- je pomalý;
- částečně rozlišuje kód a data:
 - všechny nenavštívené adresy jsou považovány za data
 - ale co tabulky skoků, nepřímo volané funkce, atd.



Rekurzivní průchod III

Rekurzivní průchod [4]

```
procedure Disassembluj( adresa, seznamInstr ) {
  if( adresa.navštívena )
    return;
  do {
    instr = DekódujInstr( adresa );
    adresa.navštívena = true:
    přidej instr do seznamInstr;
    if ( instr je větvení nebo volání funkce ) {
      T = množina možných následníků instr v toku kódu;
      for each cil in T do {
        Disassembluj(cil, seznamInstr);
    else
      adresa += instr.délka; /* adr. další instrukce */
  } while adresa je platná adresa instrukce;
```

Rekurzivní průchod — shrnutí

- Rekurzivní průchod je založen na předpokladu, že pro všechny instrukce v toku kódu dokážeme identifikovat všechny možné následníky této instrukce v toku.
- Tok kódu je sledován a všechny adresy navštívené rekurzivním průchodem jsou označeny jako kód.
- Jak spočítat možné toky kódu, pokud narazíme na nepřímý skok (skok na adresu danou tabulkou skoků, vypočítané goto nebo volání prostřednictvím VMT)? S CFG by to bylo snadné, ale my ho nemáme!
- Co dělat se zbytkem kódového segmentu, který nebyl navštíven?
 - Rekurzivní průchod se ani nepokusí tuto část disassemblovat a nedokáže o ní bez dalších analýz nic říci.
 - **Lineární průchod** by ji disassembloval, některé části dobře, jiné ne, protože představují data.
- Rekurzivní průchod má komplementární síly a slabiny ve srovnání s lineárním průchodem. Který tedy máme použít? Pokusme se vylepšit oba algoritmy.

Rozšířený lineární průchod

Lineární průchod se nedokázal vypořádat s daty vloženými do sekce .text, např. skokovými tabulkami nebo řetězcovými konstantami. Taková data zůsobovala chyby v disassembly v podobě nesprávně identifikovaných instrukcí. **Lineární průchod** ale můžeme vylepšit:

Myšlenka [4]

Pokud máme k dispozici relokační údaje, pak musí mít tabulky skoků v sekci .text záznamy v tabulce relokací. Podle těchto záznamů můžeme tabulky skoků rozpoznat a označit je jako data.

Každá záznam a; v tabulce skoků musí splňovat [4]:

- 1 paměťové lokace, v nichž a; leží, jsou označeny jako relokovatelné; a
- 2 sama adresa a; musí ležet v sekci .text.

Tabulka skoků v programu I

Ověřme si navrženou myšlenku následujícím programem:

Vzorová tabulka skoků

```
switch (intval) {
  case 0:
    func0();
    break:
  case 1:
    func1():
    break:
  case 2:
    func2();
    break;
  case 3:
    func3():
    break;
```

Vzorová tabulka skoků (assembler)

```
text:00414838
                               [ebp+intval], 3
                          CMD
                               short loc_414868
.text:0041483F
                              ecx. [ebp+intval]
text:00414841
                          mov
                          qmi
                              ds:off 41490C[ecx*4]
text:00414847
.text:0041484E loc_41484E:
.text:0041484E
                          call func0
.text:00414853
                          jmp short loc_414868
.text:00414855 loc_414855:
                          call func1
text:00414855
text:0041485A
                          imp short loc 414868
----- ZAČÁTEK dat v sekci .text ------
.text:0041490C off 40C5E0 dd offset loc 41484E // case 0
                         dd offset loc_414855 // case 1
.text:00414910
.text:00414914
                         dd offset loc_41485C // case 2
                          dd offset loc 414863 // case 3
.text:00414918
----- KONEC dat v sekci .text ------
```

Tabulka skoků v programu II

Když si vypíšeme sekci (.reloc) nástrojem dumpbin, dostaneme:

```
C:\... > dumpbin /RELOCATIONS jumptable.exe
  14000 RVA.
                  8C SizeOfBlock
                                           ----- ZAČÁTEK dat v sekci .text -----
                                            .text:0041490C off_40C5E0 dd offset loc_41484E // case 0
    90C
        HTGHT.OW
                          0041484E
    910 HIGHLOW
                          00414855
                                           .text:00414910
                                                                   dd offset loc 414855 // case 1
    914 HTCHLOW
                          0041485C
                                           .text:00414914
                                                               dd offset loc 41485C // case 2
    918 HTGHLOW
                          00414863
                                            .text:00414918
                                                                    dd offset loc_414863 // case 3
                                           ----- KONEC dat v sekci text -----
```

V relokační tabulce jsou 4 záznamy relokující 4 po sobě jdoucí ukazatele v sekci .text. Protože část x86 instrukce mohou tvořit max. 2 z nich, zbylé dva (adr. 00414914 a 00414918) musí být data. První dvě položky by mohly být kódem.

Pozn.: EXE soubory nepoužívající ASLR normálně sekci .reloc vůbec nemají, na rozdíl od DLL. Pokud je ASLR pro program povoleno, musí být binárka relokovatelná a tudíž mít sekci .reloc, podobně jako v příkladu výše.

Rozšířený lineární průchod — pokračování

Jako data jsme identifikovali pouze 2 ze 4 položek. Můžeme ale sekci .text rozčlenit do segmentů oddělených tabulkami skoků, disassemblovat veškerý kód v těchto segmentech a ověřovat, zda byla každá instrukce úspěšně disassemblována a zda nepřetekla do dat mezi segmenty. V případě přetečení nejde o instrukci, ale o data!

Rozšířený lineární průchod [4]

- Označ všechny tabulky skoků jako data, kromě prvních dvou záznamů v každé tabulce (ty mohou na x86 být součástí instrukce).
- Pro každou posloupnost neoznačených adres v sekci .text:
 - a) Použij **lineární průchod**, zastav při dosažení označené adresy.
 - b) Pokud poslední instrukce přetekla do označené adresy, označ ji jako data.
 - c) Prozkoumej poslední úspěšně disassemblovanou instrukci a v případě potřeby ji označ jako data.

Hybridní přístup

Rekurzivní průchod má komplementární síly a slabiny vůči **lineárnímu průchodu**. Zkusme zkombinovat to nejlepší z obou přístupů [4] a:

- Použijme rozšířený lineární průchod pro prvotní disassemblování;
- Použijme rekurzivní průchod pro ověření každé nalezené funkce.

Ověření probíhá následujícím postupem:

- Na každou instrukci funkce použij rekurzivní průchod.
- Ověř každou instrukci I, získanou na adrese a_I. Pokud nebyla získána také lineárním průchodem, vyvolej chybu.
- O Pokud ve funkci nedošlo k chybě, označ funkci za správnou.

Obfuskace — motivace

Motivací pro použití obfuskačních technik je utajení vlastního kódu a ztížení jeho porozumění. Běžný software tyto techniky používá pro zabránění reverzního inženýrství schémat sériových čísel, prolomení ochrany proti kopírování, vynucení použití hardwarových donglů, zajištění DRM, atd. Malware je používá pro zabránění analýze svého kódu.

Cílem těchto technik je:

- zmást disassembler (statickou analýzu);
- zmást debugger (dynamickou analýzu);
- zmást decompiler;
- zmást člověka, který výše uvedené nástroje používá.

Mezi obfuskační techniky zahrnujeme obfuskaci kódu, transformace toku kódu, šifrování, používání kontrolních součtů, detekci debuggeru, antidebugovací kód, atd. Čím delší čas si analýza vyžádá, tím méně lidí ji bude dělat :-).

Kategorizace ochran [1]

Ochrana duševního vlastnictví může být členěna na:

- právní
- technickou
 - obfuskace
 - šifrování
 - (částečný) běh na serveru
 - důvěryhodný nativní kód

Na transformační cíl můžeme aplikovat:

- obfuskaci rozložení
- obfuskaci řízení
- obfuskaci dat
- preventivní transformaci

Obfuskační metriky I

Obfuskace

Obfuskace činí objekt nesrozumitelným. V počítačovém softwaru jí rozumíme proces změny transformačního cíle tak, aby mu bylo obtížné rozumět, ale zůstala zachována jeho funkcionalita.

Transformační cíl

Transformačním cílem rozumíme objekt, který má být obfuskován. Tímto cílem může být zdrojový kód programu, ale také program v binární podobě.

Příklady transformačních cílů:

- javascriptový kód ve vašich HTML stránkách;
- javové třídy a archívy, zdrojové soubory i spustitelný kód .NET;
- zdrojový kód v PHP, C/C++, ...;
- spustitelné programy.



Obfuskační metriky II

Obfuskovaným produktem rozumíme transformační cíl poté, co na něj byly aplikovány obfuskující transformace. Každá z těchto transformací by měla, vedle zachování původního chování programu, být **potentní**, **odolná**, a její **cena** by měla být co nejnižší.

Potence [1]

Potence $\mathcal{T}_{pot}(P)$ měří, jak moc transformace programu P na obfuskovaný program P' zmate lidského čtenáře:

$$\mathcal{T}_{pot}(P) = E(P')/E(P) - 1,$$

kde E(P) je složitost P podle **nějaké** metriky.

Můžeme použít metriky jako **délka programu**, **cyklomatická složitost**, **složitost vnoření**, **složitost datového toku**, ...; obfuskace pak zvyšuje složitost toho, co daná metrika měří.



Obfuskační metriky III

Odolnost (resilience) [1]

Odolnost měří, jak obtížné je odstranit transformaci automatickým deobfuskátorem.

 $\mathcal{T}_{res} = \mathsf{Resilience}(\mathcal{T}_{prace\ deobfuskatoru},\ \mathcal{T}_{prace\ programatora}),$ kde $\mathcal{T}_{prace\ programatora}$ vyjadřuje množství času potřebné pro vytvoření automatického deobfuskátoru, který sníží \mathcal{T}_{pot} , a $\mathcal{T}_{prace\ deobfuskatoru}$ vyjadřuje dobu běhu a velikost prostoru, které auto-deobfuskátor použije pro snížení \mathcal{T}_{pot} .

Odolnost \mathcal{T}_{res} může být: **triviální**, slabá, silná, plná, nebo jednosměrná.

$\mathcal{T}_{\textit{pr. deob.}} \setminus \mathcal{T}_{\textit{pr. prog.}}$	Lokální	Globální	Meziprocedurová	Meziprocesová
Polynomiální	triviální	slabá	silná	plná
Exponenciální	slabá	silná	plná	plná

Tabulka : Odolnost($\mathcal{T}_{prace\ deobfuskatoru}$, $\mathcal{T}_{prace\ programatora}$) [1].



Obfuskace rozložení (Layout Obfuscations) I

Obfuskace rozložení [1] se zaměřuje na lexikální strukturu aplikace. Ta zahrnuje formátování zdrojového kódu, komentáře, jména proměnných a funkcí, rozložení tříd a datových struktur, atd.

Před obfuskací:

```
static public float PrümērnāZnāmkaStudenta(Student student) {
  float znāmka = 0.0f; float kredity = 0.0f;
  /* Znāmka spočītāna jako vāžený prümēr g=sum(znāmka_i*kredity_i)/sum(kredity_i) */
  if( student.Předměty().Empty() ) return 0.0f;
  for_each(předmět in student.Předměty()) {
    znāmka += předmět.Kredity() * předmět.Znāmka();
    kredity += předmět.Kredity();
  }
  return znāmka/kredity;
}
```

Po obfuskaci (odstraněny komentáře, typy, metody a třídy přejmenovány):

```
static public float a(a b) {
  float c = 0.0f; float d = 0.0f;
  if( b.a().a() ) return 0.0f;
  for_each(e in b.a()) {
    c += e.a() * e.b();
    d += e.a();
  }
  return c/d;
```

Obfuskace rozložení (Layout Obfuscations) II

Tranformace	Potence	Odolnost	Cena
Přejmenování identifikátorů	střední	jednosměrná	nulová
Změna formátování	nízká	jednosměrná	nulová
Odstranění komentářů	vysoká	jednosměrná	nulová
Odstranění ladících informací	vysoká	jednosměrná	nulová

Tabulka: Kvalita obfuskací rozložení [1].

Transformace řízení

Transformace řízení obfuskují tok kódu. Můžeme je rozčlenit na tranformace **pořadí**, **agregace**, a **výpočtu** [1].

- Transformace agregace rozdělují výpočty, které patří k sobě, a spojují ty, které k sobě nepatří.
- Transformace pořadí znáhodňují pořadí výpočtů.
- Transformace výpočtu přidávají zbytečný a/nebo mrtvý kód nebo provádějí změny v algoritmech.

Mnohé z obfuskací řízení závisí na použití **neprůhledných proměnných** (opaque variables) a **neprůhledných predikátů** (opaque predicates).

Neprůhledné predikáty a proměnné l

Proměnnou nebo predikát označíme jako neprůhledné, pokud je jejich hodnota nebo vlastnost známa obfuskujícímu v době obfuskování, ale pro deobfuskátora je obtížné ji odhadnout [1].

Neprůhledný konstrukt se skládá z příkazu **if** testujícího hodnotu neprůhledného predikátu nebo proměnné ovar na specifickou hodnotu VAL, která byla známa v době obfuskování:

```
if( ovar == VAL ) if( ovar == VAL ) if( ovar == VAL )

nikdy nenastane něco udělej něco udělej

else else
něco udělej nikdy nenastane něco udělej
```

Naším hlavním cílem je zmást jak disassembler, tak člověka, který kód studuje. Podívejme se nejprve na disassembler.

Neprůhledné predikáty a proměnné II

Lineární průchod neumí rozlišit kód od dat, a proto je zranitelný daty (smetí, tabulky skoků, ...) umístěnými uvnitř funkcí nebo mezi nimi. Využijeme této skutečnost k naplnění nikdy neprováděné větve neprůhledného predikátu s nesmyslnými daty. Ta můžeme vytvořit uvnitř bloku _asm klíčovým slovem _emit:

Klíčové slovo _emit je použito ke vložení instrukce jmp do binárky. Disassemblery používající **lineární průchod** pak typicky pochopí instrukci imul jako část operandu instrukce jmp.

26 / 62

Neprůhledné predikáty a proměnné III

```
216 00f0482f 33c0 xor eax.eax
217 00f04831 83f801 cmp eax.1
218 00f04834 7501 jne HelloWorld!wWinMain+0xb7 (00f04837)

HelloWorld!wWinMain+0xb6 [c:\users\tomas zahradnicky\documents\visual stud
219 00f04836 e9f7ea8b45 jmp

HelloWorld!wWinMain+0xb7 [c:\users\tomas zahradnicky\documents\visual stud
220 00f04837 f7ea imul edx
```

Obrázek : WinDbg 6.12.0002.633

```
00F0482F 33C0 XOR EAX,EAX CMP EAX, EAX CMP E
```

Obrázek : OllyDbg 1.10 Obrázek : OllyDbg 2.01

Skutečnost, že kód ve větvi nikdy_nenastane nebude nikdy spuštěn, je snadno detekovatelná **rekurzivním průchodem**.

FFFF

Neprůhledné predikáty a proměnné IV

```
.text:0041482F
                              xor
                                      eax, eax
                                                                     .text:0041482F
                                                                                                                  eax, eax
.text:00414831
                              CMD
                                      eax. 1
                                                                     .text:00414831
                                                                                                         CMD
                                                                                                                  eax. 1
.text:00414834
                              inz
                                      short near ptr loc 414836+1
                                                                     .text:00414834
                                                                                                         jnz
                                                                                                                  short loc 414837
.text:00414836
                                                                     .text:00414834
.text:00414836 loc 414836:
                                                      ; CODE XREF:
                                                                     text:88414836
                                                                                                         dh BE9h
.text:00414836
                              imp
                                                                     .text:00414837
.text:00414836
.text:8881883B
                              dh BEAh
                                                                     .text:00414837
                                                                     .text:00414837 loc 414837:
                                                                     .text:00414837
                                                                                                         i mull
                                                                                                                  edx
```

Obrázek: IDA Pro 6.7 původní.

Obrázek : IDA Pro 6.7 po opravě.

Pozn.: I když tato transformace může disassembler zmást, je triviálně opravitelná člověkem. Potence je tudíž **nízká**. Použitý konstrukt může být odstraněn automatickým deobfuskátorem v polynomiálním čase v rámci lokální procedury. Z těchto důvodů je odolnost **triviální**. Cena je ovšem **levná**, což činí tuto techniku tak populární.

Použijeme nyní **neprůhledný predikát** ke zmatení jak lineárních, tak rekurzivních disassemblerů. Kód uvedený níže si přečte ze zásobníku security cookie 1 a zxoruje ho s hodnotou ebp 2. Obdobný kód nalezneme na konci funkcí chráněných kanárkem. Náš kód ho používá jako neprůhlednou hodnotu.

Výsledek xoru na řádku 2 by teoreticky mohl být nula, ale není to pravděpodobné (1 : 2³²). Když není nula 3, pokračujeme řádkem 7. To je standardní tok kódu. Disassembler nedokáže určit, zda je podmínka vždy pravdivá nebo nepravdivá, protože je počítána za běhu. _emit na řádku 4 vytvoří náhodnou instrukci jxx skákající 0x00 bajtů za sebe 5, tj. na začátek dalšího _emit na řádku 6. Tento _emit vytvoří první bajt náhodné instrukce jmp nebo call. Zbylé její bajty se vezmou z instrukcí následujících za makrem.

Makro <code>OBFUSKUJ</code> přijímá hodnotu <code>_random</code> jako argument, aby při každém použití generovalo poněkud odlišný kód. Celkem může vytvořit 64 různých kombinací.

```
OBFUSKUJ(238);
cbSelf.QuadPart = 0;
OBFUSKUJ(372);
MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
OBFUSKUJ(118);
CreateConsole();
OBFUSKUJ(235);
```

```
OBFUSKUJ(238):
cbSelf.QuadPart = 0;
OBFUSKUJ(372);
MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
                              8B45 FC
OBFUSKUJ(118):
                              75 03
                                                              HelloWor,010DCC7E
CreateConsole():
                              ZE
EA
                                 ØF57CØ66 ØF13
                                                   JMP FAR 130F:66C0570F
OBFUSKUJ(235);
                              ΕĊ
                              8B45 FC
                                                       EAX.DWORD PTR SS:[EBP-4]
                              75 03
                                                       SHORT HelloWor.010DCC90
                              74 00
                                                            HelloWor.010DCC8F
                                                   DB EB
                              8D45 EC
                                                   EA EAX.DWORD PTR SS:[EBP-14]
                              8D45 10
                                                       EAX.DWORD PTR SS:[EBP+10]
                              8055 FC
                                                       EDX.DWORD PTR SS:[EBP-4]
                                                       ECX.DWORD PTR SS:[EBF
                                  10010000
                                                           lloWor.010DCDC0
                                                   ADD ESP.8
MOU EAX.DWORD PTR SS:[EBP-4]
                              8845 FC
                                                          ŔT HelloWor.010DCCB0
                              75 03
                              76 00
                                                       SHORT HelloWor.010DCCAF
                              ĒΒ
                                                   DB EB
                                                        HelloWor.010DCEA0
```

```
OBFUSKUJ(238):
cbSelf.QuadPart = 0;
OBFUSKUJ(372);
MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
                   00C1CC74
                                 8B45 FC
                                               MOV EAX.DWORD PTR SS:[EBP-4]
                                 33C5
75 03
7E 00
EA 8D45EC0F
OBFUSKUJ(118):
                                               XOR EAX.EBP
                   00C1CC77
CreateConsole();00C1CC79
                                               JNE SHORT 00C1CC7E
                                               JLE SHORT 0001007D
                                               JMP FAR C057:0FEC458D
                   00C1CC7D
OBFUSKUJ(235);
                   00C1CC84
                                               DB 50
                                 8Ď
                   00C1CC85
                                               DB 8D
                                               DB
                                                  45
                                 66
0F
13
                                               DB 66
                   00C1CC89
                                               DΒ
                                                  ØF
                                                  13
                   00C1CC8A
                                               DB
                   00C1CC8B
                                 45
                                               DB 45
                                 ÉČ
                                               DB ÉC
                   00C1CC8C
                                               DD FC558D50
                   00C1CC8D
                                 508D55FC
                   ЙØС1СС91
                                 8D
                                               DB 8D
                   00C1CC92
                                 4Đ
                                               DB 4D
                   00010093
                                               DB F8
                   00C1CC94
                                               DB E8
                   00C1CC95
                                               DB F7
```

```
OBFUSKUJ(238):
cbSelf.QuadPart = 0;
OBFUSKUJ(372);
MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
                      .text:0040CC74
                                                    mov
                                                            eax. [ebp-41
OBFUSKUJ(118):
                      .text:0040CC77
                                                    xor
                                                            eax, ebp
                                                           short near ptr loc_40CC7D+1
                      .text:0040CC79
                                                    inz
CreateConsole()
                     .text:0040CC7B
                                                    ile
                                                            short $+2
                      .text:0040CC7D
OBFUSKUJ(235);
                                                                           : CODE XREF: .text:0040CC7Bfi
                      .text:0040CC7D loc 40CC7D:
                      .text:0040CC7D
                                                                            ; .text:0040CC791j
                      .text:0040CC7D
                                                    imp
                      .text:0040CC7D
                      .text:0040CC84
                                                    dd 10458D50h, 45130F66h, 558D50ECh, 0F84D8DFCh, 0F7E8h
                      .text:0040CC84
                                                    dd 1D2E800h. 0A6A0000h. 50F4458Dh. 5045E856h. 758BFFFFh
                                                    dd 14C48310h, 5589CE8Bh, 0E8F88BE8h, 224h, 774F685h
                      .text:0040CC84
                                                    db 56h, 0FFh, 15h
                      .text:0040CCC0
                      .text:0040CCC3
                                                    dd offset UnmapViewOfFile
                      .text:0040CCC7
                                                    dh 8Bh
                      .text:0040CCC8
                                                    dd 358BEC45h
                      .text:0040CCCC
                                                    dd offset CloseHandle
                      .text:0040CCD0
                                                    dd 74FFF883h, 0D6FF5003h, 83F8458Bh, 374FFF8h, 0EBD6FF50h
                      .text:0040CCD0
                                                    dd 0F8C1E901h. 83C03302h. 17501F8h. 83EAF7E9h. 2E7703FFh
                      .text:0040CCF8
```

Podívejme se, jak tato technika zafunguje na tomto kódu v C:

```
OBFUSKUJ(238);
cbSelf.QuadPart = 0;
OBFUSKUJ(372);
MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
OBFUSKUJ(118);
CreateConsole();
OBFUSKUJ(235);
```

Naše snaha sice zmátla debuggery s **lineárním** i **rekurzivním průchodem** a možná i některé lidi, není ale o mnoho **potentnější** než předchozí verze. Také její **odolnost** je jen mírně lepší; jako neprůhlednou hodnotu používáme kanárka, mohli bychom použít i návratovou adresu, a ani jedno by statické analyzátory neměly dokázat předpovědět, pokud ovšem nepochopí, co skutečně testujeme. **Odolnost** je tedy **slabá**. Jak bychom ji mohli zvýšit?

Transformace výpočtu

Transformace výpočtu patří mezi transformace toku, které **skrývají skutečný tok kódu** za **irelevantními instrukcemi**, přidávají kód, pro který ve vyšším jazyku není vyjádření, **vkládají mrtvý kód**, nebo odstraňují skutečné abstrakce toku či vkládají falešné [1]. To zahrnuje:

- Vkládání mrtvého nebo nerelevantního kódu
- Rozšíření podmínek cyklů
- Konverzi reducibilního CFG na nereducibilní
- Odstranění knihovních volání a programovacích idiomů
- Tabulkovou interpretaci
- Přidávání redundantních argumentů
- (Nesmyslnou) paralelizaci kódu

Vkládání mrtvého nebo nerelevantního kódu I

Tyto transformace přidávají kód, který není relevantní pro původní program, aby zmátly čtenáře. Toho dosahují použitím neprůhledných predikátů nebo přidáním kódu, který s původní funkcionalitou vůbec nesouvisí.

Neprůhledné predikáty můžeme vkládat kamkoliv v bloku kódu. Pro další ztížení analýzy můžeme dát do obou větví predikátu stejný kód, ale chráněný odlišnými transformacemi, případně do nesprávné větve dát kód podobný, ale dělající něco (mírně) odlišného.

Nerelevantní kód může například provádět totožný výpočet, ale jeho výsledek ukládat do jiné proměnné.

Vkládání mrtvého nebo nerelevantního kódu II

Příklad použití této techniky už jsme viděli:

```
OBFUSKUJ(238);
cbSelf.QuadPart = 0;
OBFUSKUJ(372);
MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
OBFUSKUJ(118);
CreateConsole();
```

Kód vložený makrem OBFUSKUJ používal neprůhlednou proměnnou, kanárka, k vytvoření mrtvé větve, která nikdy nebude spuštěna.

Další příklad:

Rozšíření podmínek cyklů

Rozšíření podmínek cyklů komplikuje rozhodnutí o ukončení smyčky zahrnutím neprůhledného predikátu nebo proměnné do ukončovací podmínky:

```
char array[10];
unsigned int i;
for( i=0: i<10: ++i )
  arrav[i] = i:
Po transformaci:
char arrav[10]:
unsigned int i , j, k ;
for( i=0 , j=1, k=0 ;
   (k<170) && ((j%2)==1):
  ++i , k+=17 )
  array[i] = i;
   j|=k;
```

```
.text:0040CDA0 sub_40CDA0
                               xor
                                    eax, eax
.text:0040CDA2 loc_40CDA2:
                                     [eax+ecx], al
                               mov
.text:0040CDA5
                               inc
                                     eax
                                    eax, OAh
text:0040CDA6
                               cmp
.text:0040CDA9
                                    short loc_40CDA2
text:0040CDAR
                               retn
.text:0040CD70 sub 40CD70
                               push esi
.text:0040CD71
                                    esi, ecx
.text:0040CD73
                                    edx, edx
                                                   // i
                               xor
.text:0040CD75
                                    ecx. 1
.text:0040CD7A
                               xor eax, eax
.text:0040CD7C
                                    esp, [esp+0]
                                                   // align no-op
.text:0040CD80 loc 40CD80:
                               test cl. 1
.text:0040CD83
                                    short loc 40CD95
.text:0040CD85
                                    ecx, eax
.text:0040CD88
                                    [edx+esi], dl
                               mov
                                    eax, 11h
.text:0040CD8B
                               add
.text:0040CD8E
                                    edx
                               inc
                                    eax, OAAh
.text:0040CD8F
                               cmp
.text:0040CD94
                                    short loc 40CD80
                               ib
.text:0040CD96 loc_40CD95:
                               pop
                                    esi
.text:0040CD97
```

Konverze reducibilního CFG na nereducibilní I

Cílem této transformace je zesložitit graf toku kódu a zabránit dekompilaci.

- Graf toku funkce je reducibilní, pokud používá pouze strukturované příkazy, např. for-smyčky, do-while-smyčky, while-smyčky, if-then(-else), break, a continue.
- Jakmile začneme používat goto snadné v C/C++, nemožné v Javě (ale možné v Javovém bytekódu (!)) — stane se graf toku nereducibilním.
- Nereducibilní grafy toku vedou na odpudivý kód vyšší úrovně. To je zvlášť dobře viditelné v Javě, kde klíčové slovo goto není k dispozici.
- Do této kategorie spadá také používání konstruktů, pro které jazyk vyšší úrovně nemá vyjádření.

Konverze reducibilního CFG na nereducibilní II

Začneme s jednoduchým programem v Javě a podíváme se na jeho bytekód [5]:

```
.method public static main([Ljava/lang/String;)V
public class a
                                           .limit stack 3
 static public void main(String[] args)
                                           .limit locals 2
                                             iconst_0
    int i;
                                             istore_1; met002_slot001
   for(i=0: i<10: ++i)
                                           met002 2:
                                             iload_1; met002_slot001
      System.console().writer().
                                             bipush 10
       println("Krok: " + i):
                                             if icmpge met002 42
                                             invokestatic java/lang/System.console()Ljava/jo/Console:
                                             invokevirtual java/io/Console.writer()Ljava/io/PrintWriter:
                                             new java/lang/StringBuilder
                                             dup
                                             invokespecial java/lang/StringBuilder.<init>()V
                                             ldc "Krok: "
                                             invokevirtual java/lang/StringBuilder.append(Ljava/lang/Str
                                               ing:)Liava/lang/StringBuilder:
                                             iload 1 : met002 slot001
                                             invokevirtual java/lang/StringBuilder.append(I)Ljava/lang/StringBui
                                             invokevirtual java/lang/StringBuilder.toString()Ljava/lang/String;
                                             invokevirtual java/io/PrintWriter.println(Ljava/lang/String;)V
                                             iinc 1 1
                                             goto met002_2
                                           met002 42:
```

Konverze reducibilního CFG na nereducibilní III

```
.method public static main([Ljava...
limit stack 3
limit locals 2
 iconst_0
 istore 1 : met002 slot001
met.002 2:
  iload_1; met002_slot001
 bipush 10
  if_icmpge met002_42
  invokestatic java/lang/System.con...
  invokevirtual java/io/Console.wri...
  new java/lang/StringBuilder
 dup
  invokespecial java/lang/StringBui...
  ldc "Krok: '
  invokevirtual java/lang/StringBui...
  iload 1 : met002 slot001
  invokevirtual java/lang/StringBui...
  invokevirtual java/lang/StringBui...
  invokevirtual java/io/PrintWriter...
  iinc 1 1
 goto met002_2
met002 42:
  return
end method
```

```
// Decompiled by Jad v1.5.8e. Copyright 2001 Pavel Kouznetsov.
// Jad home page: http://www.geocities.com/kpdus/jad.html
import java.jo.Console:
import java.io.PrintWriter;
public class a
  public a() { }
  public static void main(String args[])
    for(int i = 0; i < 10; i++)
      System.console().writer().println((new StringBuilder()).
        append("Krok: ").append(i).toString());
}
// Decompiled by JD-GUI 1.0.0, JD-Core 0.7.1
// JD home page: http://id.benow.ca/
import java.io.Console;
import java.io.PrintWriter;
public class a
  public static void main(String[] paramArrayOfString)
    for (int i = 0; i < 10; i++) {
      System.console().writer().println("Krok: " + i):
 }
7
                        4 日 5 4 周 5 4 3 5 4 3 5
```

Konverze reducibilního CFG na nereducibilní IV

Jak jsme viděli, dekompilovaný výsledek byl velmi přesný. Nyní zkusíme přidat neprůhledný predikát a příkaz goto. Predikát zavolá metodu java.util.Random.nextInt(), aby načetl náhodné číslo. Výsledek bude vždy v intervalu [0, 9].

```
new java/util/Random ; Vytvoř novou instanci třídy
dup ; Zdvoj ji na vrcholu zásobníku
invokespecial java/util/Random.<init>()V ; Volej ctor, výsledek je void
bipush 10 ; Dej bajt na zásobník
invokevirtual java/util/Random.nextInt(I)I ; Volej nextInt(10), výsledek je int
```

Na vrcholu zásobníku je nyní náhodné číslo. Porovnáme ho s 10.

```
bipush 10 ; Dej bajt na zásobník if_icmpge never ; If random >= 10 GOTO never
```

V první iteraci otestujeme jinou horní mez:

```
iload_1
bipush 12
goto test_bounds
```

Konverze reducibilního CFG na nereducibilní V

```
.method public static main([Liava/lang/String:)V
.limit stack 4
.limit locals 2
 iconst 0
 istore 1 : met002 slot001
 new java/util/Random
 dup
 invokespecial java/util/Random.<init>()V
  bipush 10
  invokevirtual java/util/Random.nextInt(I)I
  bipush 10
  if_icmpge never
  iload 1
 bipush 12
  goto test_bound
loop_start:
  iload 1
  bipush 10
test bound:
  if_icmpge met002_42
  invokestatic java/lang/System.console()Ljava/io/Console;
  invokevirtual java/io/Console.writer()Ljava/io/PrintWriter:
 new java/lang/StringBuilder
  dup
  invokespecial java/lang/StringBuilder.<init>()V
  ldc "Krok: "
  invokevirtual java/lang/StringBuilder.append(Ljava/lang/String;)Ljava/lang/StringBuilder;
  iload 1
```

Konverze reducibilního CFG na nereducibilní VI

```
invokevirtual java/lang/StringBuilder.append(I)Ljava/lang/StringBuilder;
    invokevirtual java/lang/StringBuilder.toString()Ljava/lang/String;
    invokevirtual java/io/PrintWriter.println(Ljava/lang/String;)V
  never:
    iinc 1 1
   goto loop_start
 met002 42:
    return
  end method
// Decompiled by JD-GUI 1.0.0, JD-Core 0.7.1
// JD home page: http://jd.benow.ca/
import java.io.Console:
import java.io.PrintWriter:
import java.util.Random;
public class b
 public static void main(String[] paramArrayOfString)
    int i = 0:
    if (new Random().nextInt(10) < 10)
      tmpTernarvOp = 12:
      System.console().writer().println("Krok: " + i);
   i++:
```

Konverze reducibilního CFG na nereducibilní VII

```
// Decompiled by Jad v1.5.8e. Copyright 2001 Pavel Kouznetsov.
// Jad home page: http://www.geocities.com/kpdus/jad.html
import java.io.Console;
import java.io.PrintWriter;
import java.util.Random;
public class b
 public b() { }
 public static void main(String args∏)
   int i = 0:
    if((new Random()).nextInt(10) >= 10) goto _L2; else goto _L1
 L1:
   i; 12; goto _L3
 L7:
   i: 10:
 L3:
    JVM INSTR icmpge 65; goto _L4 _L5
  L4:
   break MISSING_BLOCK_LABEL_31;
  L5:
   break: /* Loop/switch isn't completed */
   System.console().writer().println((new StringBuilder()).append("Krok: ").append(i).toString());
 _L2:
   i++: if(true) goto L7: else goto L6
  L6:
```

Konverze reducibilního CFG na nereducibilní VIII

Dekompilátory se nechaly zmást použitím příkazu goto. Když zkusíme to samé udělat v C, zjistíme, že v něm tato metoda moc účinná není:

```
__declspec(noinline)
                                               .text:0040CDC0
void LoopsIred1(volatile char* array) {
                                               .text:0040CDC3
  int i:
                                               .text:0040CDC4
                                               .text:0040CDC5
  asm{
                                               .text:0040CDC9
   mov esi, arrav
                                               text:0040CDCD
   mov edi. esi
                                               .text:0040CDCF
                                               .text:0040CDD4
  // Opaque predicate, always false
  if ((__security_cookie
                                               .text:0040CDDC
                                               .text:0040CDDE
        security cookie complement) != 0)
                                               text:0040CDE0
   goto insideloop:
                                               .text:0040CDE4
  for (i = 0; i < 10; ++i) {
   arrav[i] = i:
                                               .text:0040CDE7
                                               text:0040CDE8
   insideloop:
                                               .text:0040CDE9
    asm {
                                               .text:0040CDEC
      lodsh
                                               text:0040CDEE
     ror al,1
                                               .text:0040CDF1
      stosh
                                               .text:0040CDF3
                                               .text:0040CDF4
                                               .text:0040CDF5
                                               .text:0040CDF8
```

```
sub esp, 8
               push esi
               push edi
               mov [esp+10h+var_8], ecx
               mov esi, [esp+10h+var_8]
               mov
                   edi. esi
               mov eax. security cookie complement
               xor eax, ___security_cookie
.text:0040CDDA inz short never taken
               xor edx. edx
              jmp short loc_40CDE9
               mov edx, [esp+10h+var 4]
               lodsh
.text:0040CDE5 ror al, 1
               stosb
               inc edx
               cmp edx, OAh
               ige short loc_40CDF3
               mov [edx+ecx]. dl
               jmp short loc_40CDE4
               pop
                   edi
               pop
                   esi
               add esp. 8
               retn
```

Konverze reducibilního CFG na nereducibilní IX

```
char usercall sub 40CDC0@<al>(char *pArray@<ecx>) {
 char *v1:
            // esi@1
           // edi@1
 char *v2:
 char result; // al@1
 signed int i; // edx@2
 char v5; // al@4
 signed int v6; // [sp+Ch] [bp-4h]@0
 v1 = pArray;
 v2 = pArray:
 result = security cookie ^ security cookie complement:
 if ( security cookie != security cookie complement ) {
   i = v6
   goto LABEL_4;
 for ( i = 0; i < 10; ++i ) {
   pArray[i] = i;
   LABEL 4:
   v5 = *v1++:
   result = __ROR1__(v5, 1);
   *v2++ = result:
 return result:
```

Jak vidíme, naše obfuskace není v C/C++ efektivní. IDA funkci dekompilovala skoro dokonale, včetně použití instrukce ror. V Javě byla situace úplně jiná, protože tam nebylo goto, které bychom potřebovali použít!

MI-REV, 2017, Přednáška 4

Konverze reducibilního CFG na nereducibilní X

Je zjevné, že potence závisí na jazyku, který obfuskujeme, a na kvalitě neprůhledného predikátu. V Javě je potence **střední** až **vysoká**, protože můžeme používat bytekódové instrukce, které nemají protějšek v původním jazyku. V C je potence **nízká** až **střední**.

Odolnost silně závisí na deobfuskátoru.

Cena této obfuskace je **nízká**.

Odstranění knihovních volání a programovacích idiomů

Volání knihovních funkcí poskytne analytikovi mnoho informací o našem programu. Tato volání navíc nemůžeme přejmenovat. Jejich obfuskace lze dosáhnout naprogramováním vlastních alternativ a použitím těchto alternativ místo původních API. To může zahrnovat funkce pro manipulaci s řetězci, alokaci paměti, třídy STL, atd. Ty všechny můžeme nahradit alternativními implementacemi, které mohou být přejmenované a obfuskované. To navíc zvýší velikost kódu, což činí techniku poměrně potentní (střední) a poskytuje odolnost, která je silná. Cena závisí na tom, co chceme nahradit.

Do této kategorie spadá také pozměnění běžně používaných programovacích idiomů, jako je procházení spojovým seznamem, polem, atd. Můžeme nahradit spojový seznam něčím jiným?

Tabulková interpretace I

Odolnost této obfuskace je silná, ale také je drahá cena. Ve své nejjednodušší podobě vyžaduje rozdělení části programového kódu do několika (nebo mnoha) kusů a použití smyčky s mnoha iteracemi, přičemž v každé se spustí jen jeden kus. Vhodné je použít příkaz switch, vypočítaná goto nebo tabulky skoků. Pokud chceme odolnost ještě navýšit, může mít tabulka dvě nebo více úrovní!

Tento tabulkový přístup si můžeme představit také jako běh nakouskovaného programu v miniaturním virtuálním stroji. Každý kus má své číslo, které reprezentuje operační kód "VM-instrukce". Seznam čísel kusů pak tvoří program VM! Pokud chceme jít ještě dále, můžeme každou instrukci vybavit jejími vlastními operandy, můžeme zavést registry, proměnné, atd.

Tabulková interpretace II

```
int WINAPI _tWinMain(
    HINSTANCE hInstance,
    HINSTANCE hIrevInstance,
    LPTSTR lpCmdLine,
    int nCmdShow
)
{
    HANDLE hFile = INVALID_HANDLE_VALUE;
    HANDLE hMapping = INVALID_HANDLE_VALUE;
    LPVOID pSelf = NULL;
    LARGE_INTEGER cbSelf;
/*1*/ cbSelf.QuadPart = 0;
/*2*/ MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
/*3*/ CreateConsole();
/*4*/ ExamineRelocations( pSelf, cbSelf );
/*5*/ UnmapSelfFromMemory(hFile, hMapping, pSelf);
/*6*/ return 0;
```

```
int WINAPI _tWinMainAsTable(
    HINSTANCE hInstance,
    HINSTANCE hPrevInstance,
    LPTSTR lpCmdLine,
    int nCmdShow
) {
    HANDLE hFile = INVALID_HANDLE_VALUE;
    HANDLE hMapping = INVALID_HANDLE_VALUE;
    LPVOID pSelf = NULL;
    LARGE_INTEGER cbSelf;

// Až do tohoto místa je program beze změny!
// Nyní nadefinujeme instrukce naší VM.
// Tzn. pro každý řádek vlevo označený
// /***/ zavedeme samostatnou instrukci.
// Zavedeme také instrukci pro no-op!
```

Tabulková interpretace III

```
int WINAPI _tWinMain(
 HINSTANCE hInstance.
 HINSTANCE hPrevInstance,
 LPTSTR lpCmdLine,
 int nCmdShow
 HANDLE hFile = INVALID HANDLE VALUE:
 HANDLE hMapping = INVALID_HANDLE_VALUE;
 LPVOID pSelf = NULL;
 LARGE INTEGER cbSelf:
 /*5*/ cbSelf.QuadPart = 0;
 /*1*/ MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
 /*4*/ CreateConsole();
 /*0*/ ExamineRelocations( pSelf, cbSelf );
 /*3*/ UnmapSelfFromMemory(hFile, hMapping, pSelf);
 /*6*/ {}
 /*2*/ return 0;
```

```
int WINAPI tWinMainAsTable(
 HINSTANCE hInstance,
 HINSTANCE hPrevInstance,
 LPTSTR lpCmdLine,
 int nCmdShow
 HANDLE hFile = INVALID HANDLE VALUE:
 HANDLE hMapping = INVALID_HANDLE_VALUE;
 LPVOID pSelf = NULL;
 LARGE INTEGER cbSelf:
 typedef enum instr {
    instr init size = 5, instr map file = 1,
    instr_create_console = 4, instr_return = 2
    instr_examine_relocations = 0, instr_nop = 6
   instr_unmap_file = 3
 l instr:
 // Instrukce byly očíslovány náhodně.
 // Rozsah zůstal zachován, ale nejsou v
 // pořadí. To nemá na program vliv.
 // Nyní vytvoříme program pro naši VM.
```

// --- posloupnost zavedených instrukcí.

Tabulková interpretace IV

```
int WINAPI tWinMain(
 HINSTANCE hInstance.
 HINSTANCE hPrevInstance,
 LPTSTR lpCmdLine,
 int nCmdShow
 HANDLE hFile = INVALID HANDLE VALUE:
 HANDLE hMapping = INVALID_HANDLE_VALUE;
 LPVOID pSelf = NULL;
 LARGE INTEGER cbSelf:
 /*5*/ cbSelf.QuadPart = 0;
 /*1*/ MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
 /*4*/ CreateConsole();
 /*0*/ ExamineRelocations( pSelf, cbSelf );
 /*3*/ UnmapSelfFromMemory(hFile, hMapping, pSelf);
 /*6*/ {}
 /*2*/ return 0;
```

```
int WINAPI tWinMainAsTable(
 HINSTANCE hInstance,
 HINSTANCE hPrevInstance,
 LPTSTR lpCmdLine,
 int nCmdShow
 HANDLE hFile = INVALID HANDLE VALUE:
 HANDLE hMapping = INVALID_HANDLE_VALUE;
 LPVOID pSelf = NULL;
 LARGE INTEGER cbSelf:
 typedef enum instr {
    instr init size = 5, instr map file = 1,
    instr_create_console = 4, instr_return = 2
    instr_examine_relocations = 0, instr_nop = 6
   instr unmap file = 3
 l instr:
 static instr g_Instructions[] = {
    instr_nop, instr_init_size, instr_map_file,
   instr_nop, instr_create_console, instr_nop,
   instr_examine_relocations, instr_nop,
   instr_unmap_file, instr_nop, instr_return
 1:
```

Tabulková interpretace V

```
int WINAPI tWinMain(
 HINSTANCE hInstance.
 HINSTANCE hPrevInstance,
 LPTSTR lpCmdLine,
 int nCmdShow
 HANDLE hFile = INVALID HANDLE VALUE:
 HANDLE hMapping = INVALID_HANDLE_VALUE;
 LPVOID pSelf = NULL;
 LARGE INTEGER cbSelf:
 /*5*/ cbSelf.QuadPart = 0;
 /*1*/ MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
 /*4*/ CreateConsole();
 /*0*/ ExamineRelocations( pSelf, cbSelf );
 /*3*/ UnmapSelfFromMemory(hFile, hMapping, pSelf);
 /*6*/ {}
 /*2*/ return 0:
```

```
typedef enum instr {
  instr_init_size = 5, instr_map_file = 1,
  instr create console = 4, instr return = 2
  instr examine relocations = 0, instr nop = 6
  instr_unmap_file = 3
} instr;
static instr g Instructions [] = {
  instr_nop, instr_init_size, instr_map_file,
  instr_nop, instr_create_console, instr_nop,
  instr_examine_relocations, instr_nop,
  instr_unmap_file, instr_nop, instr_return
};
for (
  unsigned int i = 0:
  i < sizeof(g_Instructions) / sizeof(instr);</pre>
  switch (g_Instructions[i])
    // Větve neisou prohozeny, pro přehlednost
    case instr_init_size:
      cbSelf.QuadPart = 0:
      break:
    case instr_map_file:
      MapSelfIntoMemory(hFile, hMapping,
        pSelf, cbSelf);
      break:
    case instr_create_console:
      CreateConsole();
      break:
```

Tabulková interpretace VI

```
int WINAPI tWinMain(
 HINSTANCE hInstance.
 HINSTANCE hPrevInstance,
 LPTSTR lpCmdLine.
  int nCmdShow
 HANDLE hFile = INVALID HANDLE VALUE:
 HANDLE hMapping = INVALID_HANDLE_VALUE;
 LPVOID pSelf = NULL;
 LARGE INTEGER cbSelf:
 /*5*/ cbSelf.QuadPart = 0;
 /*1*/ MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
 /*4*/ CreateConsole();
 /*0*/ ExamineRelocations( pSelf, cbSelf );
 /*3*/ UnmapSelfFromMemory(hFile, hMapping, pSelf);
 /*6*/ {}
 /*2*/ return 0:
```

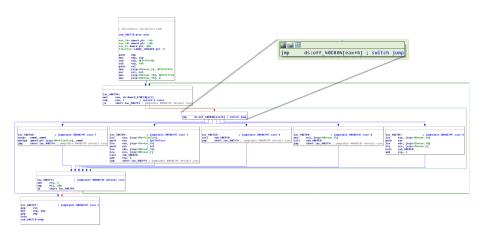
```
static instr g_Instructions[] = {
  instr_nop, instr_init_size, instr_map_file,
  instr nop, instr create console, instr nop,
  instr_examine_relocations, instr_nop,
  instr_unmap_file, instr_nop, instr_return
};
for (
  unsigned int i = 0;
  i < sizeof(g_Instructions) / sizeof(instr);</pre>
  ++i
  switch (g Instructions[i])
    // Větve nejsou prohozeny, pro přehlednost
    case instr_init_size:
      cbSelf.QuadPart = 0:
      break;
    case instr map file:
      MapSelfIntoMemory(hFile, hMapping,
        pSelf, cbSelf);
      break:
    case instr_create_console:
      CreateConsole():
      break:
    case instr_examine_relocations:
      ExamineRelocations(pSelf, cbSelf):
      break;
    case instr unmap file:
      UnmapSelfFromMemory(hFile, hMapping, pSelf);
      break:
           4 D > 4 D > 4 D > 4 D >
```

Tabulková interpretace VII

```
int WINAPI tWinMain(
 HINSTANCE hInstance.
 HINSTANCE hPrevInstance,
 LPTSTR lpCmdLine.
 int nCmdShow
 HANDLE hFile = INVALID HANDLE VALUE:
 HANDLE hMapping = INVALID_HANDLE_VALUE;
 LPVOID pSelf = NULL;
 LARGE INTEGER cbSelf:
 /*5*/ cbSelf.QuadPart = 0;
 /*1*/ MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
 /*4*/ CreateConsole():
 /*0*/ ExamineRelocations( pSelf, cbSelf );
 /*3*/ UnmapSelfFromMemory(hFile, hMapping, pSelf);
 /*6*/ {}
 /*2*/ return 0:
static instr g Instructions [] = {
 instr_nop, instr_init_size, instr_map_file,
 instr_nop, instr_create_console, instr_nop,
 instr examine relocations, instr nop.
 instr_unmap_file, instr_nop, instr_return
};
```

```
for (
  unsigned int i = 0;
  i < sizeof(g Instructions) / sizeof(instr);</pre>
  ++i
  switch (g_Instructions[i])
    // Větve nejsou prohozeny, pro přehlednost
    case instr init size:
      cbSelf.QuadPart = 0:
      break:
    case instr_map_file:
      MapSelfIntoMemory(hFile, hMapping,
        pSelf, cbSelf):
      break:
    case instr_create_console:
      CreateConsole():
      break;
    case instr examine relocations:
      ExamineRelocations(pSelf, cbSelf):
      break;
    case instr_unmap_file:
      UnmapSelfFromMemory(hFile, hMapping, pSelf);
      break;
    case instr_nop: break;
    case instr return: return 0:
 }
```

Tabulková interpretace VIII



Obrázek : wWinMain pomocí tabulkové interpretace.

Tabulková interpretace IX

Jak jsme viděli, náš program se obfuskací kompletně změnil. Srdcem funkce je nyní instrukce:

```
jmp dword ptr ds:[0040c804+4*eax]
```

Tabulka skoků je globální proměnná, stejně jako program pro VM (00410e10).

```
.rdata:00410E10 dword_410E10 dd 6, 5, 1, 6
.rdata:00410E20 dd 4, 6, 6, 0
.rdata:00410E30 dd 6, 3, 6, 2
```

Množství kódu významně vzrostlo, důsledkem je vysoká potence této transformace vzhledem k metrice "velikost kódu". Odolnost transformace je silná. Cena za převod programu touto transformací je naneštěstí drahá.

Přidání redundantních argumentů I

Redundantní argumenty zvyšují délku programu a jeho složitost. A nemusíme jen přidávat argumenty metodám/funkcním — můžeme rozšiřovat aritmetické výrazy pomocí neprůhledných proměnných.

Pozn.: Při provádění redundantních operací v plovoucí řádové čárce si musíme dávat pozor na dodatečná zaokrouhlení, která ovlivní přesnost spočítané proměnné.

Použití této metody jsme si mohli povšimnout v příkladu na rozšíření podmínek cyklů. Druhý iterátor j tam byl redundantní, stejně jako všechny výpočty nad ním.

Přidání redundantních argumentů II

```
int RedundantOps( int iRedundantBound ) {
                                                   .text:000AC780
                                                                  xor
                                                                         ecx, ecx
    int i:
                                                   .text:000AC782
                                                                  push
                                                                        ebx
    static unsigned char array[256];
                                                   .text:000AC783
                                                                  lea
                                                                        edx. [ecx-1]
    static unsigned char oarray[256];
                                                                        al, dl
                                                   .text:000AC786
                                                                  mov
                                                                        ebx, [ecx+1]
                                                   text:000AC788
                                                                  lea
    for( i=0: i<iRedundantBound: ++i ) {</pre>
                                                   .text:000AC78B
                                                                        d٦
                                                                  imul
      oarrav[i] = (i + 1)(i + 1);
                                                   .text:000AC78D
                                                                  mov
                                                                        dl, al
      oarray[i]-= (i - 1)(i - 1);
                                                   .text:000AC78F
                                                                  mov
                                                                        al, bl
      arrav[i]=oarrav[i]-3*i:
                                                   .text:000AC791
                                                                  imul
                                                                        h1
                                                   .text:000AC793
                                                                  sub
                                                                        al, dl
                                                                        dl, cl
                                                   .text:000AC795
                                                                  mov
    return 0:
                                                                        d1. d1
                                                   .text:000AC797
                                                                   add
                                                                        byte_B3F60[ecx], al
                                                   .text:000AC799
                                                                  mov
                                                                        ebx, [edx+ecx]
                                                   .text:000AC79F
                                                                  lea
Zde jsme funkci přidali redundantní
                                                                        al, bl
                                                   .text:000AC7A2
                                                                  sub
                                                                        byte B4060[ecx], al
                                                   text:000AC7A4
                                                                  mov
argument int iRedundantBound, a
                                                   .text:000AC7AA
                                                                  inc
                                                                        ecx
také redundantní neprůhledné pole static
                                                   .text:000AC7AB
                                                                  cmp
                                                                        ecx, 100h
unsigned char oarray. Argument
                                                   .text:000AC7B1
                                                                  il
                                                                        short loc AC783
                                                   .text:000AC7B3
                                                                  xor
                                                                        eax, eax
iRedundantBound obsahuie horní
                                                   .text:000AC7B5
                                                                         ebx
                                                                  pop
mez pole a volající ho vždy nastaví na 256.
```

Neprůhledné pole je použito pouze jako prostor pro výpočet $(i+1)^2 - (i-1)^2 - 3i = i$. Výsledkem pak inicializujeme array[i]=i. Množství kódu vzrostlo, takže potence je střední až vysoká, ale odolnost transformace je slabá. Transformation je však levná.

.text:000AC7B6

retn

Paralelizace kódu I

Vlákna se používají pro provádění více operací souběžně tak, že rozčleníme problém na menší kusy, vyřešíme je samostatně a pak sloučíme výsledky. Tentýž princip můžeme použít pro obfuskaci:

- Pokud jsou bloky datově nezávislé: necháme každé vlákno vyhodnocovat jeden blok posloupnosti.
- Pokud jsou bloky datově závislé: vytvoříme posloupnost bloků kódu, necháme ve vlákně spustit první blok, pak odblokujeme druhé vlákno a provedeme druhý blok, atd.
- Můžeme vytvořit několik vláken, které nedělají nic užitečného, jen používají neprůhledné predikáty, vyhazují výjimky, . . .)

Paralelizace kódu II

Potence paralelizace kódu je **vysoká**, protože paralelním programům je těžké pozorumět. Odolnost je **silná**, protože automatický deobfuskátor musí zvažovat všechna vlákna a jejich možné interakce v programu, což může vést až ke složitosti O(n!)! Cena transformace programu na paralelní je **drahá**.

Paralelizaci obvykle provádíme prostřednictvím vláken. Pro zvýšení odolnosti (plná) můžeme části kódu přesunout do samostatných procesů a využít nějakou formu meziprocesové komunikace (sdílená paměť, pojmenované či anonymní roury, sdílené soubory, lokální či vzdálené sockety, koncové body RPC, ...) pro synchronizaci.

Paralelizace kódu III

```
int WINAPI tWinMain(
 HINSTANCE hInstance.
 HINSTANCE hPrevInstance,
 LPTSTR lpCmdLine,
 int nCmdShow
 HANDLE hFile = INVALID HANDLE VALUE:
 HANDLE hMapping = INVALID_HANDLE_VALUE;
 LPVOID pSelf = NULL;
 LARGE INTEGER cbSelf:
 cbSelf.QuadPart = 0;
 MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf);
 CreateConsole():
 ExamineRelocations( pSelf, cbSelf );
 UnmapSelfFromMemory(hFile, hMapping, pSelf);
 return 0:
```

Každý řádek programu transformujeme na samostatné vlákno. Thread1 a Thread2 mohou běžet souběžně. Thread3 musí počkat, než obě skončí. Thread4 musí počkat na Thread3 a používá pro to události Windows. Thread5 musí počkat na Thread4

```
volatile LONG declspec(align(8))
  g ThreadOneTwoDone = 0:
LPVOID WINAPI Thread1(LPVOID pUserData) {
  LARGE INTEGER* pcbSelf = (LARGE INTEGER*)pUserData:
  pcbSelf->QuadPart = 0;
  InterlockedIncrement( &g_ThreadOneTwoDone );
  return 0:
7
LPVOID WINAPI Thread2(LPVOID pUserData) {
  CreateConsole():
  InterlockedIncrement( &g_ThreadOneTwoDone );
  return 0;
LPVOID WINAPI Thread3(LPVOID pUserData) {
  while( g ThreadOneTwoDone != 2 )
  MapSelfIntoMemory(hFile, hMapping, pSelf, cbSelf):
  SetEvent(...); /* odblokuj vlákno 4 */
  return 0;
LPVOID WINAPI Thread4(LPVOID pUserData) {
  WaitForSingleObject(...); /* počkej na vlákno 3 */
  ExamineRelocations( pSelf, cbSelf );
  SetEvent(...); /* odblokuj vlákno 5 */
 return 0:
}
```

4 日 5 4 周 5 4 3 5 4 3 5

Inlining I

Inliningem rozumíme proces kopírování těla funkce do všech míst, odkud je funkce volána.

Kompilátory používají inlining v rámci optimalizace pro krátké funkce, konstruktory, atd., aby ušetřily na režii prologu a epilogu, předávání argumentů a provádění instrukce call.

```
int F1()
                                                                             int main()
int main()
                            f1;
                                                                               m1;
  m1:
                            f2;
                                                                               f1;
                                              \rightarrow inlining \rightarrow
  F1();
                                                                               f2:
  m2:
                                                                               m2;
                         int G1()
  G1():
                                                                               g1;
  m3;
                                                                               m3:
                            g1;
```

Funkce F1 a G1 v transformovaném produktu vůbec neexistují a informace o nich je nenávratně ztracena — inlining je **jednosměrná** transformace.

Inlining II

Obfuskátory používají inlining pro zvýšení složitosti funkcí. Čím víc lokálních proměnných a řádků kódu funkce má, tím obtížnější je ji analyzovat, protože obfuskace odstranila abstrakce použité programátorem. Reverzní inženýr nebude vědět, jaká funkce byla inlinovaná a kam, obzvlášť pokud byly inlinovány všechny kopie funkce a originál už se v programu vůbec nevyskytuje.

Inlining je levná transformace, její potence je střední a odolnost jednosměrná, obzvlášť pokud ji zkombinujeme s následující technikou — outliningem.

Outlining

Proces outliningu je inverzní k inliningu. Část kódu funkce je vytržena z těla funkce, postavena stranou, zkonvertována na samostatnou funkci a na původním místě nahrazena instrukcí call. Použití outliningu vede, zejména při souběžném použití s inliningem, k potentním a odolným transformacím:

```
m1:
                                                                                     f1:
int main()
                                                         int main()
                                                                                  int G1()
  m1;
  f1;
                      \rightarrow outlining \rightarrow
                                                            F1();
  f2;
                                                                                     f2:
                                                            G1();
  m2;
                                                                                     m2;
                                                            H1():
  g1;
                                                                                     g1;
  m3:
                                                                                  int H1()
```

int F1()

Interleaving I

Interleaving je optimalizační technika využívající fyzickýxh vlastností média k zvýšení přístupových nebo přenosových rychlostí. U obfuskaci rozumíme interleavingem techniku, kdy se kód a argumenty dvou nebo více funkcí spojují do funkce jediné, společně s novým argumentem (nebo globální proměnnou), který dovolí volajícímu vybrat jednu z větví.

```
\begin{array}{l} \text{int F1()} \\ \{ \\ \text{f1;} \\ \text{f2;} \\ \} \end{array} \qquad \rightarrow \text{interleaving} \rightarrow \\ \text{int G1()} \\ \{ \\ \text{g1;} \\ \} \end{array}
```

```
int H1(int which)
{
    switch (which) {
        case 1:
            f1;
            f2;
            break;
        case 2:
            g1;
            break;
};
```

Klonování

Obfuskace pomocí klonování metod se poněkud podobá použití neprůhledných predikátů v tom, že vytváří nadbytečná větvení, která musí reverzní inženýr analyzovat. Nepoužívá však neprůhledné predikáty, ale mechanismy programovacího jazyka pro výběr metod. Toho je dosaženo tranformací jediné rodičovské třídy C s virtuální metodou na hierarchii (nebo sadu) tříd C1, C2, atd., přičemž každá vznikla z C pomocí jiné obfuskační transformace. Reverznímu inžěnýrovi se bude zdát, že volání závisí na konkrétní instanci třídy, ve skutečnosti ovšem provádějí všechny instance přesně totéž.

Transformace smyček

Pro účely obfuskace lze dále využít různé transformace smyček:

- Loop Blocking označuje techniku rozdělení těla smyčky do několika částí tak, aby se vešly do cache, a tím lépe využily vlastností cacher dané architektury.
- Loop Unrolling replikuje tělo smyčky několikrát po sobě, čímž eliminuje potřebu skoků na další iteraci a umožňuje lepší optimalizaci využití registrů. To je obzvlášť efektivní v případech, kdy je počet iterací předem znám.
- Loop Fission dělí smyčku na několik samostatných smyček se stejným iteračním mechanismem, ale různými těly. Tyto smyčky pak mohlou například běžet paralelně.

Všechny tyto techniky zvyšují metriky kódu jako je velikost nebo cyklomatická složitost, což zajišťuje jejich potenci. Jejich odolnost je slabá, pokud jsou použity izolovaně, ale výrazně roste v kombinaci s dalšími obfuskačními technikami. Cena je levná, někdy nulová.

Literatura I

- Collberg C., Thomborson C., Low, D.: A Taxonomy of Obfuscating Transformations, Technical Report #148, University of Auckland, Auckland, New Zealand, 1997/2009. Available online at https://researchspace.auckland.ac.nz/bitstream/handle/2292/3491/TR148.pdf.
- Eilam, E.: Reversing Secrets of Reverse Engineering, Wiley Publishing, Inc., 2005.
- Eagle, C.: The IDA Pro Book The unofficial guide to the world's mode popular disassembler, 2nd ed., No Starch Press, 2011.
- Schwarz, B., Debray, S., Andrews, G.: Disassembly of Executable Code Revisited, Proceedings of the IEEE Working Conference on Reverse Engineering, Oct. 2002, pp. 45-54. Available online at http://ftp.cs.arizona.edu/~debray/Publications/disasm.pdf.

Literatura II



Wikipedia Foundation, Inc.: Java bytecode instruction listings, Available online at https://en.wikipedia.org/wiki/Java_ bytecode_instruction_listings, 2015.